Paradigme des couches de neurones appliqué aux lois élastoplastiques 1D et 3D

AKKAD Ahmed **Abdelkhalek Mnaouer**

ahmed.akkad@etu.u-pec.fr abdelkhalek.mnaouer@etu.u-pec.fr

Encadré par **Felipe Figueredo Rocha**

felipe.figueredo-rocha@u-pec.fr

Université Paris-Est Créteil (UPEC), laboratoire MSME

Résumé

Ce papier propose une approche *data-driven* afin de modéliser des lois de comportement élastoplastiques. Des données synthétiques sont générées à partir de modèles constitutifs classiques et utilisées pour entraîner un réseau de neurones. L'étude est menée progressivement sur une loi élastoplastique 1D, puis sur une loi 3D multiaxiale de type plasticité (von Mises) avec écrouissage isotrope linéaire.

Mots-clés : élastoplasticité, plasticité de von Mises, réseaux de neurones, apprentissage profond, approche énergétique, mécanique numérique.

1 Introduction

Les lois de comportement élastoplastiques sont essentielles pour représenter la réponse non linéaire des matériaux métalliques soumis à des sollicitations mécaniques. Elles se caractérisent par l'apparition de déformations irréversibles au-delà d'une limite d'élasticité et reposent classiquement sur une loi d'élasticité, un critère de plasticité et une loi d'écrouissage [8, 9, 10]. Dans ce travail, nous considérons une loi élastoplastique 1D comme cas test, ainsi qu'une loi 3D multiaxiale basée sur le critère de von Mises avec écrouissage isotrope linéaire.

2 Loi élastoplastique

Une loi élastoplastique décrit le comportement d'un matériau en distinguant un régime élastique, où les déformations sont réversibles, et un régime plastique, où apparaît une déformation irréversible lorsque la sollicitation dépasse un seuil de plasticité. Elle s'appuie généralement sur une relation élastique, un critère de plasticité définissant le début de plastification, et une loi d'écrouissage traduisant l'évolution de ce seuil avec l'histoire de chargement. Cette formulation constitue le cadre classique de la plasticité des métaux en petites déformations, largement utilisé en mécanique des solides et en calcul numérique [8, 9].

2.1 Loi élastoplastique 1D utilisée

La loi unidimensionnelle repose sur l'élasticité linéaire, un critère de plasticité de type von Mises 1D et un écrouissage isotrope linéaire.

Équations constitutives :
La déformation totale est décomposée en une part élastique et une part plastique :

$$\boldsymbol{\varepsilon} = \boldsymbol{\varepsilon}^e + \boldsymbol{\varepsilon}^p. \tag{1}$$

La loi d'élasticité (Hooke 1D) s'écrit :

$$\sigma = E\left(\varepsilon - \varepsilon^p\right), \tag{2}$$

où E est le module d'Young.

Le critère de plasticité est défini par une fonction de charge :

$$f(\sigma, k) = |\sigma| - \sigma_y(k) \leq 0, \tag{3}$$

où k est la variable interne d'écrouissage isotrope (plasticité cumulée).

Dans le cas d'un écrouissage isotrope linéaire :

$$\sigma_y(k) = \sigma_{y0} + Hk, \tag{4}$$

où σ_{y0} correspond au seuil initial et H contrôle le durcissement.

2.2 Loi élastoplastique 3D utilisée

On considère un matériau isotrope en petites déformations, avec écrouissage isotrope linéaire. La plasticité est gouvernée par le critère de von Mises.

Le critère de von Mises est particulièrement adapté à la modélisation de la plasticité des matériaux métalliques isotropes et constitue une référence standard en mécanique computationnelle [10, 9].

Cinématique : Cas des petites déformations :
Le tenseur des déformations est défini à partir du champ de déplacement $\mathbf{u}$ par :

$$\boldsymbol{\varepsilon} = \frac{1}{2}\left(\nabla\mathbf{u} + (\nabla\mathbf{u})^T\right). \tag{5}$$

La déformation totale se décompose en une part élastique et une part plastique donnée par l'équation (1).

Équation constitutive :
La contrainte de Cauchy est donnée par la loi élastique :

$$\boldsymbol{\sigma} = \mathbb{C} : \boldsymbol{\varepsilon}^e = \mathbb{C} : (\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}^p), \tag{6}$$

où $\mathbb{C}$ est le tenseur d'élasticité.

Matériau isotrope : tenseur d'élasticité :
Pour un matériau isotrope, le tenseur d'élasticité peut s'écrire :

$$C_{ijkl} = \lambda\,\delta_{ij}\delta_{kl} + \mu\left(\delta_{ik}\delta_{jl} + \delta_{il}\delta_{jk}\right), \tag{7}$$

où λ et μ sont les coefficients de Lamé. Ils sont liés au module d'Young E et au coefficient de Poisson ν par :

$$\mu = \frac{E}{2(1+\nu)}, \qquad \lambda = \frac{E\nu}{(1+\nu)(1-2\nu)}. \tag{8}$$

Décomposition des contraintes :
On décompose la contrainte en une partie hydrostatique et une partie déviatorique :

$$\boldsymbol{\sigma} = \mathbf{s} + \frac{1}{3}\mathrm{tr}(\boldsymbol{\sigma})\,\mathbf{I}, \tag{9}$$

où $\mathbf{s}$ est le déviateur des contraintes.

Critère de von Mises et écrouissage isotrope :
La contrainte équivalente de von Mises est définie par :

$$\sigma_{\mathrm{eq}} = \sqrt{\frac{3}{2}\,\mathbf{s}:\mathbf{s}}. \tag{10}$$

Le critère de plasticité de von Mises avec écrouissage isotrope s'écrit :

$$f(\boldsymbol{\sigma}, k) = \sigma_{\mathrm{eq}} - \sigma_y(k) \leq 0. \tag{11}$$

La contrainte seuil σ_{y0} est donnée par l'équation (4).

Déformation plastique équivalente cumulée :
La variable interne k représente la *déformation plastique équivalente cumulée*. En formulation continue, elle est définie par :

$$k(t) = \int_0^t \sqrt{\frac{2}{3}\,\dot{\boldsymbol{\varepsilon}}^p : \dot{\boldsymbol{\varepsilon}}^p}\; dt. \tag{12}$$

En pratique, dans une implémentation numérique, cette définition peut être évaluée sous forme discrète :

$$k \leftarrow k + \Delta k, \qquad \Delta k = \sqrt{\frac{2}{3}\Delta\boldsymbol{\varepsilon}^p : \Delta\boldsymbol{\varepsilon}^p}. \tag{13}$$

3 Méthodologie

3.1 Configuration du réseau de neurones

Dans le cas 1D :
L'approche proposée s'inscrit dans le cadre des méthodes *data-driven* en mécanique des solides, qui visent à remplacer ou enrichir les modèles constitutifs classiques par des approximations apprises à partir de données [7, 1].
Dans le cas unidimensionnel, l'objectif est d'apprendre directement la relation constitutive entre la déformation totale et la contrainte. Le réseau de neurones approxime ainsi une fonction scalaire :

$$\varepsilon \in \mathbb{R} \quad \longmapsto \quad \sigma(\varepsilon) \in \mathbb{R}. \tag{14}$$

Le modèle utilisé est un perceptron multicouche (MLP) composé de cinq couches cachées de 200 neurones chacune. Des fonctions d'activation ReLU sont appliquées après chaque couche cachée. L'architecture adoptée est :

- Couche d'entrée : 1,
- Cinq couches cachées de 200 neurones,
- Couche de sortie : 1

La couche de sortie utilise une activation linéaire afin de permettre une prédiction continue de la contrainte.
Dans le cas 3D :
Dans le cadre 3D, l'objectif est d'apprendre une représentation énergétique du comportement élastoplastique. Le réseau de neurones utilisé (noté `EnergyNet`) approxime la densité d'énergie libre Ψ à partir du vecteur de déformation en notation de Voigt :

$$\boldsymbol{\varepsilon}^V \in \mathbb{R}^6 \quad \longmapsto \quad \Psi(\boldsymbol{\varepsilon}^V) \in \mathbb{R}. \tag{15}$$

Cette approche garantit une cohérence thermodynamique, puisque le tenseur de contraintes peut ensuite être obtenu comme dérivée de l'énergie par rapport aux déformations :

$$\boldsymbol{\sigma}^V = \frac{\partial \Psi}{\partial \boldsymbol{\varepsilon}^V}. \tag{16}$$

Cette formulation énergétique garantit la cohérence thermodynamique du modèle appris et s'inscrit dans la lignée des approches récentes visant à imposer des contraintes physiques aux réseaux de neurones en mécanique [3, 4, 2].

Le réseau utilisé est un perceptron multicouche (MLP) composé de trois couches cachées de 100 neurones chacune, avec des fonctions d'activation ReLU appliquées après chaque couche cachée. L'architecture adoptée est la suivante :

- Couche d'entrée : 6
- Trois couches cachées : 100 → 100 avec ReLU
- Couche de sortie : 1

Cette configuration a été retenue pour sa capacité à approximer des non-linéarités marquées, tout en conservant un coût de calcul raisonnable.

3.2 Génération des données d'entraînement

Dans le cas 1D :
Les données d'entraînement sont générées à partir d'une loi de comportement élastoplastique unidimensionnelle (traction) avec critère de plasticité de type von Mises 1D et écrouissage isotrope linéaire. Un historique de déformation ε est imposé sous forme d'une phase de chargement monotone suivie d'une décharge purement élastique jusqu'à annulation de la contrainte. À chaque incrément, le modèle constitutif de référence est intégré par un schéma de retour radial 1D (prédicteur élastique / correcteur plastique), ce qui permet de calculer la contrainte σ ainsi que la déformation plastique cumulée ε^p. On obtient ainsi un ensemble de couples (ε, σ) constituant la base de données utilisée pour l'apprentissage.

Dans ce cadre, les entrées du réseau correspondent à la déformation et la sortie correspond à la contrainte en unités physiques.

Dans le cas 3D :
Les données d'entraînement sont générées à partir d'une loi de comportement élastoplastique 3D de type plasticité (von Mises) avec écrouissage isotrope linéaire. Les déformations $\boldsymbol{\varepsilon}$ sont générées aléatoirement dans un voisinage des petites déformations, sous forme de vecteurs de dimension 6 en notation de Voigt. Le modèle constitutif de référence permet ensuite de calculer :

- la densité d'énergie Ψ,
- les contraintes $\boldsymbol{\sigma}^V$.

Dans notre cadre, l'énergie libre est décomposée en une contribution élastique et un terme d'écrouissage isotrope, conformément à la formulation thermomécanique classique :

$$\Psi(\boldsymbol{\varepsilon}, \boldsymbol{\varepsilon}^p, k) = \frac{1}{2}\,(\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}^p) : \mathbb{C} : (\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}^p) + \frac{1}{2}Hk^2, \tag{17}$$

où k est la variable interne associée à la déformation plastique équivalente cumulée. Enfin, une normalisation des données est appliquée afin d'améliorer la stabilité numérique de l'entraînement. Afin d'améliorer la stabilité numérique, les données de contrainte sont normalisées pendant l'entraînement. La contrainte prédite en unités physiques est reconstruite via :

$$\sigma^{\mathrm{pred}} = \sigma_n^{\mathrm{pred}}\, y_{\mathrm{std}} + y_{\mathrm{mean}}, \tag{18}$$

où σ_n^{pred} correspond à la sortie normalisée du réseau. Dans cette apprentissage, on calcule y_{mean} (la moyenne) et y_{std}

(l'écart-type) des valeurs d'énergie Ψ afin de réaliser une normalisation (centrage-réduction) des sorties du réseau. Cette étape est essentielle car les grandeurs manipulées en mécanique présentent des ordres de grandeur très différents : les déformations sont petites (de l'ordre de 10^{-3}), alors que l'énergie peut atteindre des valeurs très élevées (de l'ordre de 10^5). Sans normalisation, le réseau serait amené à apprendre sur des valeurs très grandes, ce qui rendrait l'optimisation instable (gradients trop grands ou trop petits, convergence lente, voire divergence).

En normalisant, on ramène ainsi l'énergie Ψ à des valeurs centrées autour de zéro et de variance proche de 1, ce qui améliore fortement la stabilité et la vitesse d'apprentissage. De plus, comme la contrainte est calculée ensuite par dérivation automatique, le facteur y_{std} permet également de restaurer correctement l'échelle physique des contraintes lors de la reconstruction. Ainsi, la normalisation garantit un entraînement robuste et cohérent avec les unités mécaniques.

3.3 Algorithme de return mapping (cas 1D et 3D)

L'intégration incrémentale des lois de comportement élastoplastiques considérées dans ce travail est réalisée à l'aide d'un algorithme de *return mapping* de type prédicteur–correcteur. La même structure algorithmique est utilisée pour les cas unidimensionnel (1D) et tridimensionnel (3D), la différence portant uniquement sur la définition des grandeurs mécaniques et du critère de plasticité.

Prédicteur élastique. À chaque incrément de déformation totale, un état d'essai purement élastique est d'abord calculé :

$$\boldsymbol{\sigma}_{\text{trial}} = \mathbb{C} : (\boldsymbol{\varepsilon}_{n+1} - \boldsymbol{\varepsilon}_n^p)\,, \tag{19}$$

où $\mathbb{C}$ désigne le tenseur d'élasticité. Dans le cas 1D, cette relation se réduit à

$$\sigma_{\text{trial}} = E\,(\varepsilon_{n+1} - \varepsilon_n^p)\,. \tag{20}$$

Critère de plasticité. La condition de plasticité est évaluée à l'aide de la fonction de charge :

$$f_{\text{trial}} = \sigma_{\text{eq}}^{\text{trial}} - (\sigma_{y0} + H\,k_n)\,, \tag{21}$$

où k désigne la déformation plastique équivalente cumulée. En 1D, la contrainte équivalente se réduit à $\sigma_{\text{eq}}^{\text{trial}} = |\sigma_{\text{trial}}|$, tandis qu'en 3D elle est définie par :

$$\sigma_{\text{eq}}^{\text{trial}} = \sqrt{\frac{3}{2}\,\mathbf{s}_{\text{trial}} : \mathbf{s}_{\text{trial}}}, \tag{22}$$

$\mathbf{s}_{\text{trial}}$ étant le déviateur des contraintes.

Si $f_{\text{trial}} \leq 0$, la réponse est purement élastique et les variables internes restent inchangées :

$$\boldsymbol{\sigma}_{n+1} = \boldsymbol{\sigma}_{\text{trial}}, \qquad \boldsymbol{\varepsilon}_{n+1}^p = \boldsymbol{\varepsilon}_n^p, \qquad k_{n+1} = k_n. \tag{23}$$

Correction plastique. Lorsque $f_{\text{trial}} > 0$, une correction plastique est appliquée. Le multiplicateur plastique est alors calculé par :

$$\Delta\gamma = \frac{f_{\text{trial}}}{\mathcal{H}}, \tag{24}$$

avec

$$\mathcal{H} = \begin{cases} E + H, & \text{cas 1D}, \\ 3\mu + H, & \text{cas 3D}, \end{cases}$$

où μ désigne le module de cisaillement.

La déformation plastique est mise à jour selon :

$$\boldsymbol{\varepsilon}_{n+1}^p = \boldsymbol{\varepsilon}_n^p + \Delta\gamma\,\mathbf{n}, \tag{25}$$

où la direction de plasticité $\mathbf{n}$ est définie par :

$$\mathbf{n} = \begin{cases} \text{sign}(\sigma_{\text{trial}})\,, & \text{cas 1D}, \\ \sqrt{\dfrac{3}{2}}\,\dfrac{\mathbf{s}_{\text{trial}}}{\|\mathbf{s}_{\text{trial}}\|}, & \text{cas 3D}. \end{cases}$$

La variable interne associée à l'écrouissage isotrope évolue comme :

$$k_{n+1} = k_n + \Delta\gamma. \tag{26}$$

La contrainte corrigée est finalement obtenue par la loi d'élasticité :

$$\boldsymbol{\sigma}_{n+1} = \mathbb{C} : \left(\boldsymbol{\varepsilon}_{n+1} - \boldsymbol{\varepsilon}_{n+1}^p\right), \tag{27}$$

qui se réduit en 1D à :

$$\sigma_{n+1} = E\left(\varepsilon_{n+1} - \varepsilon_{n+1}^p\right). \tag{28}$$

Cet algorithme de retour radial garantit la satisfaction du critère de plasticité, une évolution cohérente des variables internes et une intégration stable des lois de comportement élastoplastiques en 1D et en 3D, en accord avec le cadre thermomécanique de la plasticité classique.

3.4 Fonction de coût et optimisation

Pour le cas 1D : L'apprentissage du réseau consiste à approximer directement la relation contrainte–déformation. La fonction de coût est choisie comme l'erreur quadratique moyenne (MSE) entre la contrainte prédite par le réseau et la contrainte de référence issue du modèle élastoplastique 1D :

$$\mathcal{L}_{1D} = \frac{1}{N}\sum_{i=1}^{N}\left(\sigma_i^{\text{pred}} - \sigma_i^{\text{ref}}\right)^2. \tag{29}$$

L'optimisation est réalisée à l'aide de l'algorithme Adam avec un pas d'apprentissage fixé à 10^{-4}, sur 5000 époques. Les données sont utilisées en mode *batch* (l'ensemble des points à chaque itération) et la sortie du réseau reste linéaire afin de permettre une prédiction continue de la contrainte.

Pour le cas 3D : En 3D, le réseau apprend la densité d'énergie libre $\Psi(\boldsymbol{\varepsilon})$ et les contraintes sont obtenues par dérivation automatique, conformément à la formulation énergétique :

$$\boldsymbol{\sigma}^{\text{pred}} = \frac{\partial\Psi^{\text{pred}}}{\partial\boldsymbol{\varepsilon}}. \tag{30}$$

La fonction de coût combine alors (i) une perte sur l'énergie et (ii) une perte sur les contraintes, afin d'imposer simultanément la cohérence énergétique et la précision mécanique :

$$\mathcal{L}_{3D} = \alpha\,\mathcal{L}_\Psi + \beta\,\mathcal{L}_\sigma. \tag{31}$$

La perte énergétique est définie comme une erreur quadratique moyenne :

$$\mathcal{L}_\Psi = \text{MSE}\big(\Psi_n^{\text{pred}}, \Psi_n^{\text{ref}}\big)\,. \tag{32}$$

La perte sur les contraintes est également formulée comme une erreur quadratique moyenne, mais échelonnée par un facteur d'échelle :

$$\mathcal{L}_\sigma = \frac{1}{N}\sum_{i=1}^{N}\left\|\frac{\boldsymbol{\sigma}_i^{\text{pred}} - \boldsymbol{\sigma}_i^{\text{ref}}}{\sigma_{\text{scale}}}\right\|^2. \tag{33}$$

Ici, α et β pondèrent respectivement les contributions énergétique et mécanique, tandis que σ_{scale} est un facteur d'échelle introduit afin de normaliser la contribution des contraintes dans la fonction de coût et d'améliorer la stabilité numérique de l'optimisation, les contraintes présentant des ordres de grandeur nettement plus élevés que les autres grandeurs physiques. Les entrées et les sorties énergétiques Ψ sont normalisées (centrage–réduction) avant apprentissage, puis l'énergie est dénormalisée afin de retrouver l'échelle physique.

L'optimisation est effectuée à l'aide de l'algorithme Adam (pas d'apprentissage 10^{-4}) sur 5000 époques.

4 Résultats et discussion

4.1 Résultats 1D : apprentissage contrainte–déformation

Dans le cas unidimensionnel, le réseau de neurones est entraîné sur 5000 époques afin d'approximer directement la relation constitutive $\sigma(\varepsilon)$. L'apprentissage converge correctement et l'erreur quadratique moyenne finale obtenue est faible :

$$\mathcal{L}_{final} \approx 8.99 \times 10^{-3}. \tag{34}$$

Cette valeur confirme que le réseau parvient à reproduire de manière satisfaisante la loi élastoplastique 1D de référence.

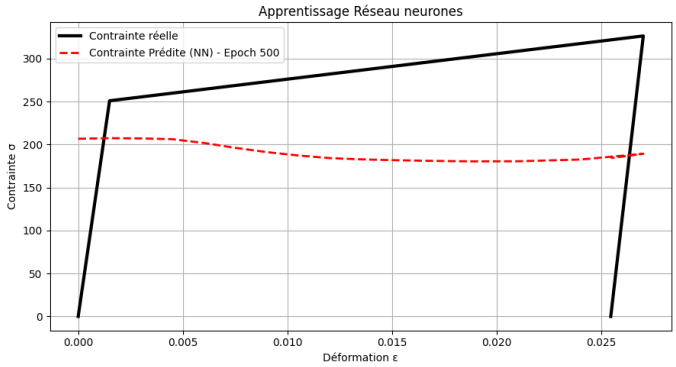

FIGURE 1 – Epoch 500

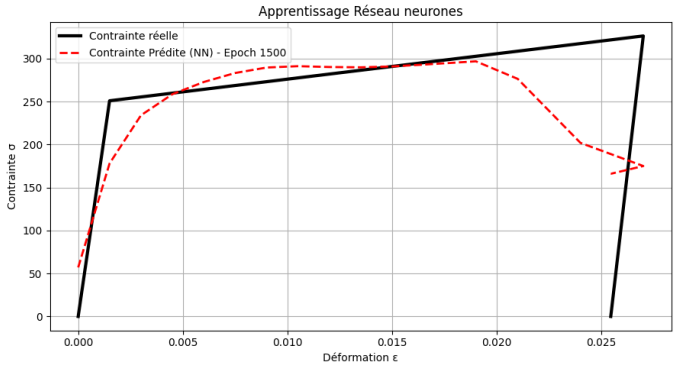

FIGURE 2 – Epoch 1500

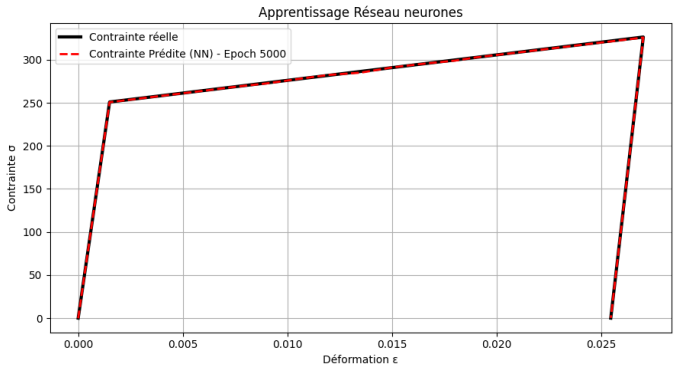

FIGURE 3 – Epoch 5000

Discussion (cas 1D)

Les résultats présentés sur les Figures 1 à 3 mettent en évidence l'amélioration progressive de la prédiction du réseau de neurones au cours de l'entraînement. À l'époque 500 (Figure 1), le réseau se situe encore dans une phase de sous-apprentissage : la contrainte prédite reste éloignée de la réponse réelle et ne reproduit pas correctement la transition élastique/plastique. À l'époque 1500 (Figure 2), on observe une nette amélioration. Le réseau commence à capturer la tendance globale de la loi de comportement, notamment l'effet d'écrouissage, bien que des écarts subsistent sur certaines zones de chargement. Enfin, à l'époque 5000 (Figure 3), la réponse prédite devient globalement cohérente avec la loi de référence. Le réseau parvient ainsi à approximer la relation contrainte–déformation élastoplastique avec une précision satisfaisante, ce qui est confirmé par la faible valeur finale de la fonction de coût ($\mathcal{L}_{final} \approx 10^{-3}$). Ces résultats valident l'approche *data-driven* pour l'identification d'une loi de comportement 1D à partir de données générées numériquement.

4.2 Résultats 3D : deux cas d'étude (traction et cisaillement)

Cas 3D – Traction (énergie et σ_{11}).

Dans ce premier cas, le réseau apprend la densité d'énergie libre et les contraintes sont reconstruites par dérivation automatique. L'entraînement converge de manière régulière : la perte totale diminue de 2.14×10^{-1} (Epoch 100) à 5.91×10^{-4} (Epoch 3500). La contribution énergie devient très faible ($\mathcal{L}_\Psi \approx 4.86 \times 10^{-6}$ à l'Epoch 3500) et la perte sur les contraintes décroît jusqu'à $\mathcal{L}_\sigma \approx 3.81 \times 10^{-5}$, indiquant une bonne reproduction de la réponse mécanique. Les pertes associées aux variables internes restent également faibles en fin d'apprentissage, ce qui confirme que la mise à jour plastique est correctement capturée.

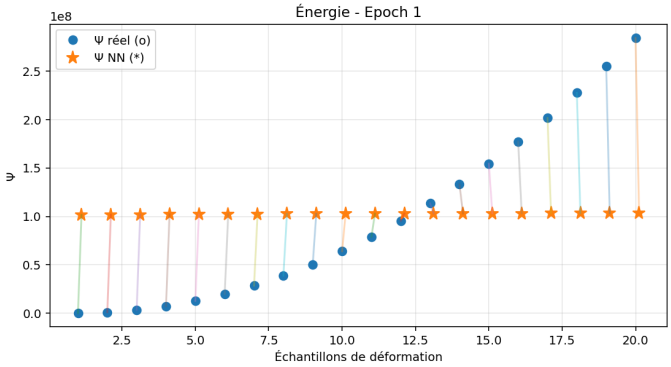

FIGURE 4 – Cas 3D traction : énergie Ψ réelle et prédite (Epoch 1).

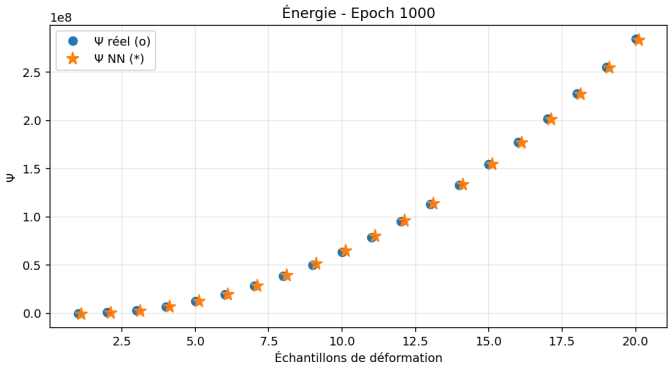

FIGURE 5 – Cas 3D traction : énergie Ψ réelle et prédite (Epoch 1000).

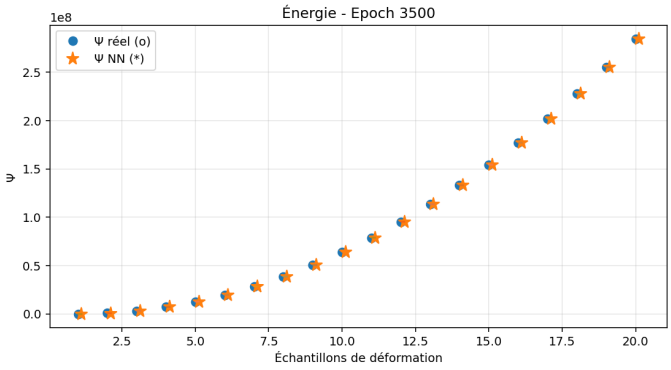

FIGURE 6 – Cas 3D traction : énergie Ψ réelle et prédite (Epoch 3500).

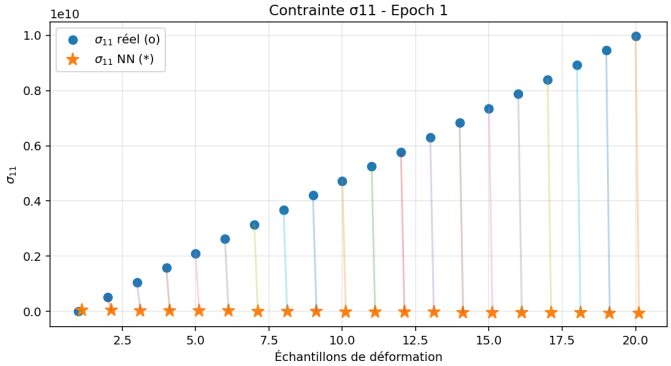

FIGURE 7 – Cas 3D traction : contrainte σ_{11} réelle et prédite (Epoch 1).

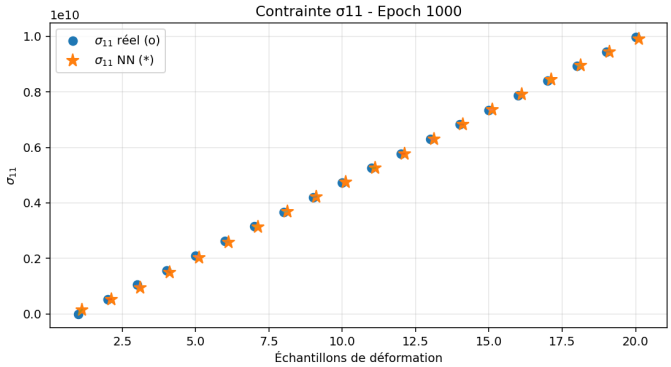

FIGURE 8 – Cas 3D traction : contrainte σ_{11} réelle et prédite (Epoch 1000).

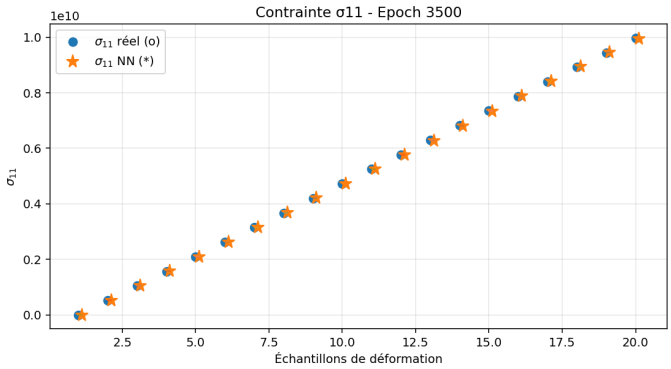

FIGURE 9 – Cas 3D traction : contrainte σ_{11} réelle et prédite (Epoch 3500).

Discussion (traction) :
Les Figures 4–6 mettent en évidence une amélioration progressive de la prédiction énergétique : le biais initial (Epoch 1) disparaît progressivement et l'énergie prédite devient quasi superposée à la référence en fin d'entraînement. La reconstruction des contraintes suit la même tendance (Figures 7–9) : la composante σ_{11} est d'abord éloignée de la réponse réelle, puis converge vers un bon accord, ce qui valide l'approche énergétique couplée à la dérivation automatique.

Cas 3D – Cisaillement (énergie et σ_{12}, σ_{13}, σ_{23}) : Dans le cas de cisaillement, la convergence est également observée mais avec une dynamique plus fluctuante au cours des premières époques. Globalement, la perte totale diminue de 1.32×10^{-1} (Epoch 100) à 1.62×10^{-4} (Epoch 3000). En fin d'apprentissage, les contributions associées à l'énergie et aux composantes de cisaillement deviennent faibles ($\mathcal{L}_\Phi \approx 1.35 \times 10^{-6}$ et des pertes de l'ordre de 10^{-5} pour σ_{12}, σ_{13} et σ_{23}), traduisant une bonne reproduction de la réponse en cisaillement.

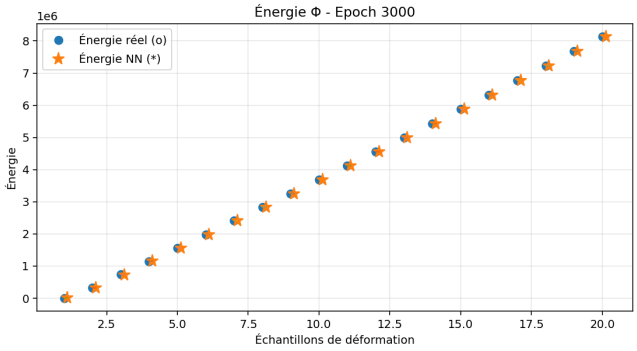

FIGURE 10 – Cas 3D cisaillement : énergie (réelle et prédite) à l'Epoch 3000.

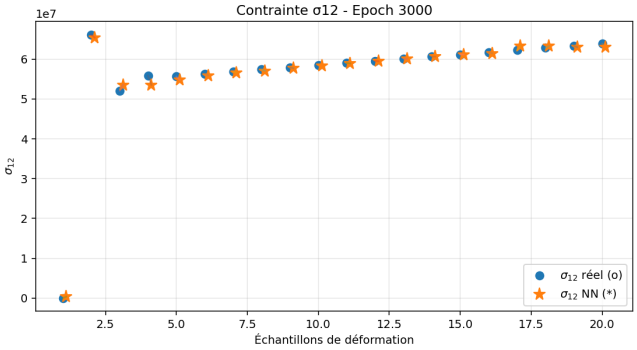

FIGURE 11 – Cas 3D cisaillement : contrainte σ_{12} réelle et prédite (Epoch 3000).

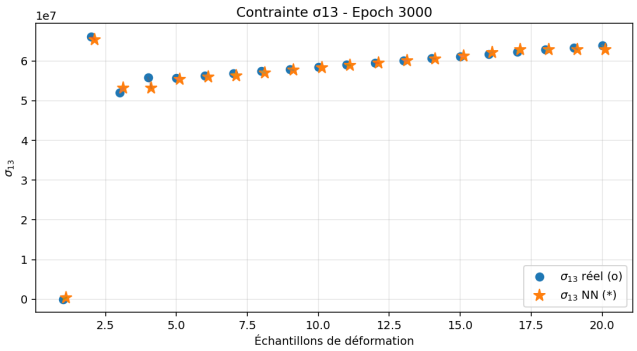

FIGURE 12 – Cas 3D cisaillement : contrainte σ_{13} réelle et prédite (Epoch 3000).

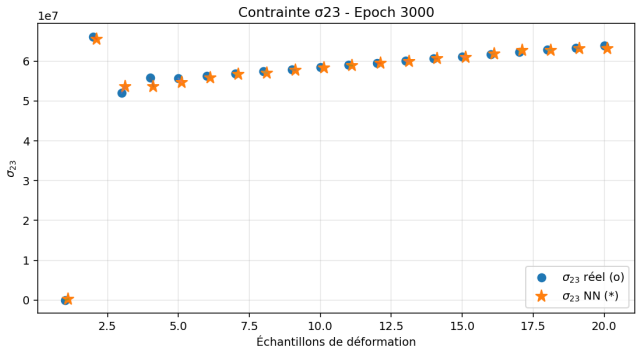

FIGURE 13 – Cas 3D cisaillement : contrainte σ_{23} réelle et prédite (Epoch 3000).

Discussion (cisaillement).
Les Figures 10–13 montrent une superposition globale entre les prédictions du réseau et les valeurs de référence, aussi bien pour l'énergie que pour les composantes de cisaillement. Les écarts résiduels restent limités et peuvent s'expliquer par la difficulté à apprendre simultanément plusieurs composantes de contrainte et une énergie cohérente avec un nombre restreint d'échantillons. Néanmoins, la faible valeur finale de la perte et la qualité des comparaisons confirment la capacité du modèle à approximer correctement le comportement élastoplastique 3D sous sollicitations de cisaillement.

Ces résultats sont en accord avec les observations récentes rapportées dans la littérature sur l'apprentissage de lois de comportement par réseaux de neurones, qui montrent que les formulations énergétiques permettent d'améliorer la robustesse et la cohérence physique des modèles appris [1, 3].

5 Conclusion

Ce travail a présenté une approche *data-driven* pour l'approximation de lois de comportement élastoplastiques en 1D et en 3D à partir de données synthétiques générées par des modèles constitutifs classiques. En 1D, un perceptron multicouche apprend directement la relation contrainte–déformation $\sigma(\varepsilon)$ et reproduit de manière satisfaisante la transition élastique/plastique ainsi que l'écrouissage isotrope. En 3D, une approche énergétique a été considérée : le réseau approxime la densité d'énergie libre $\Psi(\boldsymbol{\varepsilon})$, et les contraintes sont reconstruites par dérivation automatique, garantissant une cohérence thermodynamique. Les résultats obtenus sur deux cas d'étude (traction et cisaillement) montrent un bon accord global entre prédictions et réponses de référence, et confirment l'intérêt de la normalisation pour stabiliser l'entraînement lorsque les grandeurs présentent des ordres de grandeur très différents.

Les perspectives incluent l'extension à des chemins de chargement plus complexes (décharge/recharge, multiaxial non proportionnel), l'introduction d'écrouissage cinématique et/ou de dépendances viscoplastiques, ainsi que l'évaluation de la robustesse et de la capacité de généralisation sur des jeux de données plus riches et des cas non vus en apprentissage.

Ces travaux confirment le potentiel des approches *data-driven* et énergétiques pour la modélisation constitutive en mécanique des solides, en cohérence avec les développements récents du domaine [7, 6, 1].

Remerciements

Les auteurs remercient chaleureusement **Felipe Figueredo Rocha** pour son encadrement scientifique, ses conseils avisés et les discussions approfondies qui ont guidé ce travail. Ils lui sont également reconnaissants pour son soutien tout au long du développement de cette étude.

Références

[1] M. Zlatić, F. Rocha, L. Stainier, M. Čanaijja, *Data-driven methods for computational mechanics : A fair comparison between neural networks based and model-free approaches*, Computer Methods in Applied Mechanics and Engineering, 2024.

[2] M. Zlatić, M. Čanaijja, *Incompressible rubber thermoelasticity : a neural network approach*, Computational Mechanics, 71(4) : 895–916, 2023.

[3] L. Linden, D. K. Klein, K. A. Kalina, J. Brummund, O. Weeger, M. Kästner, *Neural networks meet hyperelasticity : A guide to enforcing physics*, Computational Mechanics, 2023.

[4] P. Linka, H. R. Kuhl, *A new family of Constitutive Artificial Neural Networks for hyperelasticity*, Preprint submitted to Computational Mechanics, 2023.

[5] E. Haghighat, E. D. Cueto, F. Chinesta, *Sobolev training : A new deep learning paradigm for data-driven physics*, Computer Methods in Applied Mechanics and Engineering, 2021.

[6] G. Karniadakis, I. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, L. Yang, *Physics-informed machine learning*, Nature Reviews Physics, 2021.

[7] F. Chinesta, E. Cueto, E. Abisset-Chavanne, J. L. Duval, M. El Khaldi, *Data-driven computational mechanics*, Springer, 2020.

[8] J. Lemaitre, J.-L. Chaboche, *Mechanics of Solid Materials*, Cambridge University Press, 1990.

[9] J. C. Simo, T. J. R. Hughes, *Computational Inelasticity*, Springer, 1998.

[10] E. A. de Souza Neto, D. Perić, D. R. J. Owen, *Computational Methods for Plasticity : Theory and Applications*, John Wiley & Sons, 2008.

[11] J. Bleyer, *Learning elastoplasticity with implicit layers*, Computer Methods in Applied Mechanics and Engineering, 2025.